Pemeringkatan Helpful-ness Ulasan Menggunakan Embedding BLaIR dan MLP pada Dataset Amazon Reviews 2023

SKRIPSI

Oleh:

Jason Nathanael
NIM. 231110013
Elvina Estelita
NIM. 231112380
Andrew Senna Wijaya
NIM. 231111369
Dickson Yangga
NIM. 231110389
Delvin De Vito
NIM. 231111185



PROGRAM STUDI S-1 TEKNIK INFORMATIKA
FAKULTAS INFORMATIKA
UNIVERSITAS MIKROSKIL
MEDAN

2026

Review Helpfulness Ranking Using BLaIR Embeddings and MLP on the Amazon Reviews 2023 Dataset

UNDERGRADUATE THESIS

By:

Jason Nathanael
NIM. 231110013
Elvina Estelita
NIM. 231112380
Andrew Senna Wijaya
NIM. 231111369
Dickson Yangga
NIM. 231110389
Delvin De Vito
NIM. 231111185



UNDERGRADUATE PROGRAM OF COMPUTER SCIENCE
FACULTY OF INFORMATICS
UNIVERSITAS MIKROSKIL
MEDAN

2026

Review Helpfulness Ranking Using BLaIR Embeddings and MLP on the Amazon Reviews 2023 Dataset

Abstrak

Abstrak minimal 100 kata dan maksimal 200 kata berbahasa Indonesia, dicetak miring dengan huruf Times New Roman 12 pt, serta dibuat dalam satu paragraf. Abstrak harus jelas, deskriptif, dan harus memberikan gambaran singkat masalah yang diteliti. Abstrak meliputi alasan pemilihan topik atau pentingnya topik penelitian, metodologi penelitian, dan ringkasan hasil. Abstrak harus diakhiri dengan komentar tentang pentingnya hasil atau kesimpulan singkat.

Kata kunci: *3 s/d 5 kata kunci dicetak miring*

Abstract

A minimum 100 words and maximum 200 words of abstract in English, in italics with Times New Roman 12 pt, and within one paragraph. Abstract should be clear, descriptive, and provide a brief overview of the problem studied. Abstract include reasons for the selected topics or the importance of research topics, research methodology, and a summary of the results. Abstract should end with comments about the importance of the results or brief conclusion.

Keywords: *3 to 5 keywords in italics*

DAFTAR ISI

Abstrak ..... **i**

DAFTAR ISI ..... **ii**

DAFTAR GAMBAR ..... **viii**

DAFTAR TABEL ..... **ix**

DAFTAR LAMPIRAN ..... **x**

1. BAB I PENDAHULUAN **11**

2. BAB II KAJIAN LITERATUR **15**

BAB III METODOLOGI PENELITIAN **23**

Komponen **24**

Uraian **24**

Input **24**

Judul dan isi ulasan, rating, status verified_purchase, timestamp, helpful_vote, parent_asin, dan asin dari Amazon Reviews 2023. ..... **24**

Proses **24**

Validasi data; preprocessing; product-disjoint split; analisis usia-vote; pembentukan target dan pasangan; embedding BLaIR; feature fusion; training MLP; serta evaluasi ranking **24**

Keluaran **24**

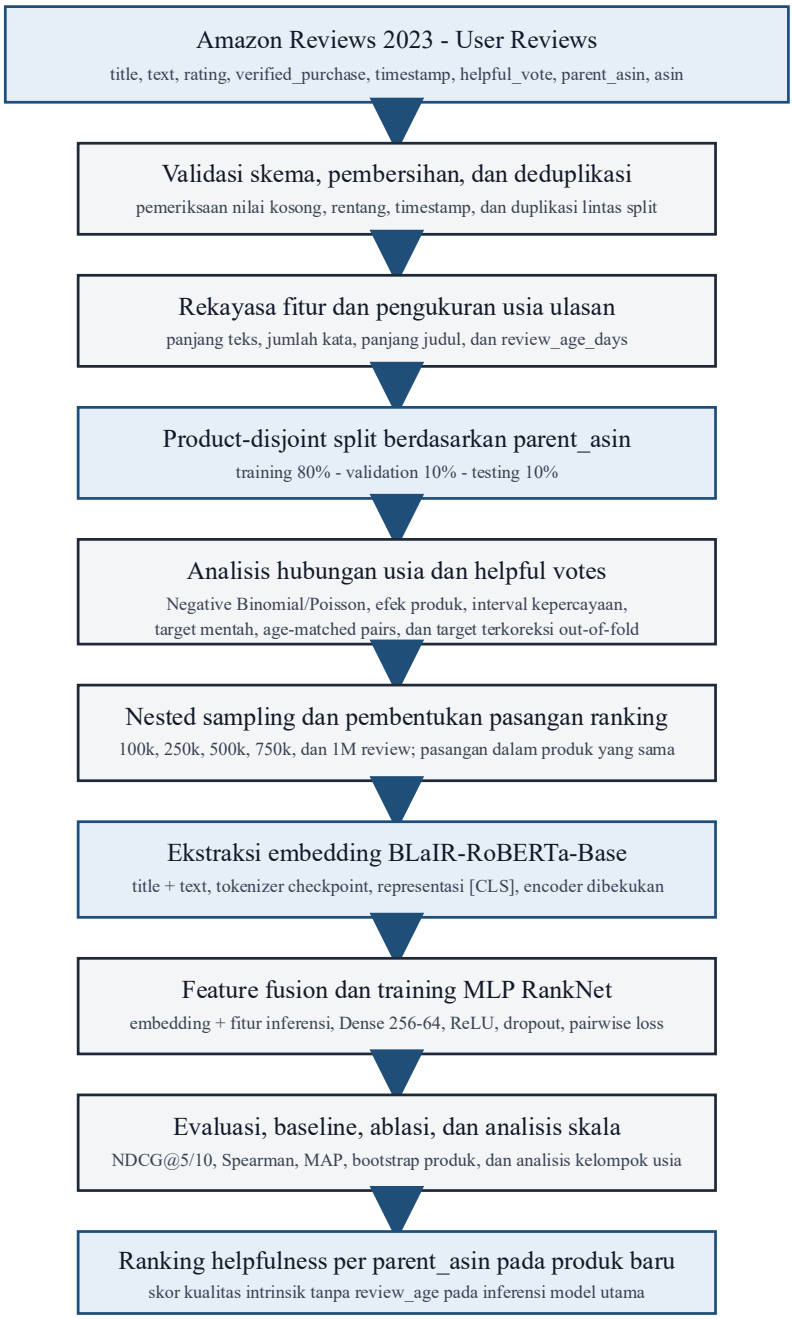
Skor ranking per ulasan, urutan ulasan per parent_asin, hasil baseline dan ablasi, kurva hubungan usia-vote, serta metrik generalisasi pada produk baru. **24**

Kendala utama **24**

Vote nol yang dominan, distribusi long-tail, perbedaan ukuran produk, bias paparan, keterbatasan komputasi, dan tidak tersedianya riwayat waktu setiap vote. **24**

Kriteria keberhasilan **24**

Peningkatan metrik ranking yang konsisten terhadap baseline pada test product-disjoint, disertai interval kepercayaan dan analisis performa menurut kelompok usia. **24**



..... 25

Bagian 27

Unit alokasi 27

Proporsi/ukuran 27

Fungsi 27

Training 27

parent_asin 27

sekitar 80% produk 27

Pelatihan model, fit preprocessing, model usia, dan pembentukan target out-of-fold. 27

Validation **27**
parent_asin **27**
sekitar 10% produk **27**
Pemilihan hyperparameter, aturan pasangan, batas usia, threshold MAP, dan early stopping. **27**
Testing **27**
parent_asin **27**
sekitar 10% produk **27**
Evaluasi akhir satu kali pada produk yang tidak terlihat. **27**
E1-E5 ..... **27**
review dalam training pool **27**
100k; 250k; 500k; 750k; 1M **27**
Mengukur pengaruh skala dengan subset nested dan validation/testing yang tetap. **27**
Atribut **28**
Peran **28**
Digunakan saat inferensi utama **28**
title **28**
Judul ulasan dan bagian input encoder **28**
Ya **28**
text **28**
Isi ulasan dan bagian input encoder **28**
Ya **28**
rating **28**
Fitur terstruktur **28**
Ya **28**
verified_purchase **28**
Fitur terstruktur kategorikal/biner **28**
Ya **28**
timestamp **28**
Perhitungan review_age dan analisis paparan **28**
Tidak **28**
helpful_vote **28**
Pembentukan target dan evaluasi **28**
Tidak **28**
parent_asin **28**

Kelompok ranking dan unit split **28**
Tidak sebagai fitur **28**
asin **28**
Pemeriksaan varian dan kebocoran **28**
Tidak sebagai fitur **28**
Jenis **29**
Alat **29**
Peruntukan **29**
Perangkat keras **29**
CPU multi-core dan RAM yang memadai **29**
Preprocessing, agregasi per produk, pembentukan pasangan, dan analisis statistik. **29**
Perangkat keras **29**
GPU NVIDIA berkemampuan CUDA dan VRAM yang memadai **29**
Ekstraksi embedding BLaIR dan pelatihan MLP. **29**
Perangkat keras **29**
Penyimpanan SSD **29**
Menyimpan dataset, embedding, split, checkpoint, dan log eksperimen. **29**
Perangkat lunak **29**
Python dan environment terisolasi **29**
Bahasa implementasi serta penguncian dependensi. **29**
Perangkat lunak **29**
PyTorch dan Hugging Face Transformers **29**
Inferensi encoder BLaIR dan pelatihan neural. **29**
Perangkat lunak **29**
Pandas/Polars, NumPy, dan scikit-learn **29**
Pemrosesan data, transformasi fitur, baseline, dan metrik. **29**
Perangkat lunak **29**
statsmodels/SciPy **29**
Model count, korelasi, interval kepercayaan, dan uji statistik. **29**
Perangkat lunak **29**
Matplotlib/Seaborn **29**
Visualisasi distribusi, kurva usia-vote, dan hasil eksperimen. **29**
Perangkat lunak **29**
Git dan pencatat eksperimen **29**
Kontrol versi kode, konfigurasi, seed, dan artefak hasil. **29**

Komponen **32**
Konfigurasi awal **32**
Input **32**
Embedding BLaIR + fitur terstruktur tertransformasi **32**
Hidden layer 1 ..... **32**
Dense 256 neuron + ReLU **32**
Regularisasi **32**
Dropout 0,2 ..... **32**
Hidden layer 2 ..... **32**
Dense 64 neuron + ReLU **32**
Output **32**
Satu skor ranking tanpa aktivasi **32**
Optimizer **32**
Adam; learning rate dan weight decay ditentukan pada validation **32**
Loss **32**
Pairwise logistic loss bergaya RankNet **32**
Kontrol training **32**
Mini-batch pasangan, early stopping NDCG@10 validation, gradient clipping bila diperlukan **32**
Kelompok **33**
Varian **33**
Tujuan **33**
Skala **33**
100k; 250k; 500k; 750k; 1M review **33**
Mengukur perubahan performa akibat penambahan data training. **33**
Baseline **33**
TF-IDF + linear; TF-IDF + MLP; BLaIR + linear **33**
Memisahkan manfaat representasi dan arsitektur. **33**
Model utama **33**
BLaIR + MLP; BLaIR + fitur + MLP **33**
Mengukur manfaat nonlinearitas dan feature fusion. **33**
Ablasi **33**
Embedding saja; +rating; +verified; +seluruh fitur inferensi **33**
Mengukur kontribusi fitur terstruktur. **33**
Kontrol usia **33**

Target mentah; age-matched; target OOF terkoreksi; koreksi + bobot lintas usia.... 33
Mengukur dampak strategi pengendalian paparan. 33
Oracle 33
Model tambahan dengan review_age 33
Mengukur upper bound informasi usia; bukan model produksi. 33
Metrik 34
Penggunaan 34
Aturan utama 34
NDCG@5 34
Kualitas lima posisi teratas 34
Dihitung per produk dengan IDCG > 0, lalu macro-average. 34
NDCG@10 34
Metrik utama kualitas ranking 34
Cut-off menggunakan min(k,n); target mentah dan terkoreksi dilaporkan terpisah [13]. 34
Spearman 34
Kesesuaian urutan monotonik 34
Produk minimal tiga ulasan dan target tidak konstan. 34
MAP 34
Presisi posisi relevan 34
Produk memiliki minimal satu relevan dan satu nonrelevan; threshold dibekukan dari training/validation. 34
MAE/RMSE 34
Akurasi prediksi ln(1+vote) 34
Hanya untuk baseline regresi atau keluaran terkalibrasi, bukan skor ranking mentah. 34
NB deviance 34
Kecocokan model count usia 34
Dibandingkan dengan model tanpa komponen usia. 34
3. BAB IV HASIL DAN PEMBAHASAN 35
4. 4.1 Hasil 35
5. 4.2 Pembahasan 36
6. BAB V PENUTUP 37
7. DAFTAR PUSTAKA 38

DAFTAR GAMBAR

Gambar 3.1 Diagram alir penelitian 25

DAFTAR TABEL

Tabel 3.1 Formulasi input, proses, dan keluaran penelitian 24
Tabel 3.2 Rancangan split dan sampel training bertingkat 27
Tabel 3.3 Atribut data dan perannya dalam penelitian..... 28
Tabel 3.4 Perangkat dan perangkat lunak penelitian 29
Tabel 3.5 Konfigurasi awal model MLP ranking 32
Tabel 3.6 Matriks eksperimen penelitian 33
Tabel 3.7 Metrik dan aturan evaluasi..... 34

DAFTAR LAMPIRAN

Abstrak ..... **i**
DAFTAR ISI ..... **ii**
DAFTAR GAMBAR ..... **viii**
DAFTAR TABEL ..... **ix**
DAFTAR LAMPIRAN ..... **x**

1. BAB I
PENDAHULUAN

1.1 Latar Belakang

Ulasan produk daring membantu calon konsumen memahami pengalaman penggunaan, kualitas, serta kekurangan suatu produk sebelum mengambil keputusan untuk membeli produk. Akan tetapi, produk populer dapat memiliki ratusan hingga ribuan ulasan dengan mutu informasi yang tidak seragam, sehingga pembaca sulit menemukan ulasan yang paling berguna. Du et al. menunjukkan bahwa volume ulasan yang besar dan variasi kualitas ulasan meningkatkan kebutuhan terhadap mekanisme otomatis untuk memprioritaskan informasi, sedangkan Amazon Reviews 2023 menyediakan lebih dari 570 juta ulasan pada sekitar 48 juta item dan 33 kategori untuk mendukung penelitian berskala besar [1], [2]. Besarnya koleksi tersebut menjadikan pemeringkatan helpfulness sebagai persoalan yang relevan bagi pengolahan bahasa alami dan sistem perdagangan elektronik.

Jumlah helpful votes lazim digunakan sebagai indikator operasional kebermanfaatan, tetapi indikator ini tidak identik dengan kualitas intrinsik ulasan. Vote bersifat kumulatif: ulasan lama mempunyai kesempatan paparan lebih panjang, sedangkan ulasan baru dan ulasan pada produk kurang populer cenderung mengalami kelangkaan vote. Nayeem dan Rafiei menunjukkan bahwa informasi temporal berperan dalam prediksi helpfulness, terutama pada kondisi cold-start [3]. Berdasarkan skema publik Amazon Reviews 2023 yang menyertai publikasi dataset [2], data User Reviews menyediakan helpful_vote, tetapi tidak mencantumkan total vote maupun riwayat waktu setiap vote. Oleh sebab itu, helpful_vote diperlakukan sebagai proksi yang dipengaruhi kesempatan paparan; nilai nol tidak langsung diartikan sebagai bukti bahwa ulasan tidak berguna.

Penelitian terdahulu memanfaatkan fitur tekstual dan nontekstual, model neural, serta pendekatan pointwise, pairwise, dan listwise [5]. Du et al. mengidentifikasi 30 fitur berbasis konten yang dikelompokkan ke dalam kategori semantik, sentimen, keterbacaan, struktur, dan sintaksis; hasil empiris mereka menunjukkan dominasi fitur semantik dalam prediksi helpfulness [1]. Nguyen et al. menunjukkan bahwa objektif listwise dapat menangkap konteks keseluruhan daftar dan selaras dengan tujuan pemeringkatan, tetapi memerlukan pemodelan daftar yang lebih kompleks [4]. Sebaliknya, pendekatan pairwise lebih sederhana dan mudah diskalakan karena mempelajari preferensi dua ulasan, meskipun tidak mengoptimalkan seluruh daftar secara langsung. Representasi berbasis TF-IDF juga efisien

dan mudah dijelaskan, tetapi kurang mampu menangkap kesamaan semantik ketika gagasan yang sama dinyatakan dengan kosakata berbeda.

Penelitian ini menawarkan pemeringkatan berbasis checkpoint hyp1231/blair-roberta-base, yang selanjutnya disebut BLaIR-RoBERTa-Base, dan Multi-Layer Perceptron (MLP) dengan pairwise ranking loss bergaya RankNet. Goel et al. mendokumentasikan checkpoint tersebut sebagai encoder berbasis RoBERTa yang diprapelatih pada judul ulasan Amazon dan menghasilkan embedding dari representasi token [CLS] [14]. Sementara itu, publikasi BLAIR menempatkan encoder semantik dalam skenario pencarian dan rekomendasi serta memperkenalkan Amazon Reviews 2023 [2]. Embedding judul dan isi ulasan digabungkan dengan rating, verified_purchase, review_length, word_count, dan title_length. Arsitektur MLP dipilih karena relatif sederhana untuk mempelajari interaksi nonlinear antarfitur, tetapi kemampuannya harus diuji terhadap baseline TF-IDF, model linear, dan konfigurasi ablasi. Checkpoint tersebut tidak dilatih khusus untuk helpfulness; karena itu, manfaatnya pada tugas ini tidak diasumsikan sebelum dibuktikan melalui eksperimen.

Untuk mengurangi bias paparan, penelitian mengukur hubungan usia ulasan dengan helpful_vote setelah mengendalikan perbedaan produk dan kovariat yang tersedia, lalu membandingkan target mentah, age-matched pairs, dan target terkoreksi usia yang dibentuk secara out-of-fold. Review_age tidak diberikan kepada model utama saat inferensi, sehingga keluaran diarahkan pada skor ranking kualitas yang lebih intrinsik, bukan ramalan jumlah vote kumulatif pada suatu horizon. Data dibagi secara product-disjoint berdasarkan parent_asin untuk menguji generalisasi pada produk baru. Kinerja dinilai dengan NDCG@5, NDCG@10, korelasi Spearman, dan MAP, disertai perbandingan skala training 100.000 hingga 1.000.000 ulasan. Rancangan ini diharapkan menghasilkan evaluasi yang lebih jujur terhadap manfaat BLaIR, fitur terstruktur, ukuran data, serta strategi pengendalian usia.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, masalah penelitian ini dirumuskan sebagai bagaimana membangun dan mengevaluasi model review helpfulness ranking berbasis embedding BLaIR-RoBERTa-Base dan MLP yang mampu melakukan generalisasi pada produk yang tidak terdapat dalam data pelatihan, sekaligus mengurangi pengaruh perbedaan kesempatan memperoleh helpful votes melalui pembentukan target dan pasangan training yang mengendalikan usia ulasan tanpa menggunakan review_age sebagai fitur model utama saat inferensi.

1.3 Tujuan

Tujuan penelitian ini adalah:

1. Mengimplementasikan BLaIR-RoBERTa-Base sebagai encoder teks dan MLP dengan pairwise ranking loss bergaya RankNet untuk menghasilkan skor pemeringkatan ulasan pada setiap produk.
2. Mengukur hubungan usia ulasan dengan jumlah helpful votes setelah mengendalikan perbedaan produk dan kovariat nonteks yang tersedia.
3. Membandingkan target mentah, age-matched pairs, serta target terkoreksi usia secara out-of-fold untuk mengurangi bias kesempatan memperoleh vote tanpa memasukkan review_age ke model utama saat inferensi.
4. Mengevaluasi kontribusi embedding BLaIR, fitur terstruktur, dan peningkatan skala data melalui baseline yang konsisten serta eksperimen ablasi.
5. Menguji kualitas ranking dan generalisasi pada produk yang tidak digunakan selama pelatihan menggunakan NDCG@5, NDCG@10, korelasi Spearman, dan MAP.

1.4 Manfaat

Manfaat yang diharapkan dari penelitian ini adalah:

1. Memberikan bukti empiris mengenai kesesuaian embedding BLaIR dan MLP untuk tugas review helpfulness ranking.
2. Menyediakan rancangan evaluasi yang membedakan kualitas intrinsik ulasan dari akumulasi vote akibat lamanya paparan.
3. Menjadi acuan bagi penelitian selanjutnya mengenai baseline, ablasi fitur, skala data, dan evaluasi pada produk baru.
4. Memberikan dasar teknis bagi platform perdagangan elektronik untuk memprioritaskan ulasan informatif tanpa menjadikan usia ulasan sebagai ketergantungan model produksi.

1.5 Ruang Lingkup

Ruang lingkup penelitian ditetapkan sebagai berikut:

1. Data yang digunakan adalah bagian User Reviews dari Amazon Reviews 2023, terutama atribut title, text, rating, verified_purchase, timestamp, helpful_vote, parent_asin, dan asin. Item Metadata tidak menjadi kebutuhan model utama.

2. Unit pemeringkatan adalah kumpulan ulasan dalam parent_asin yang sama; asin digunakan untuk memeriksa keterkaitan varian dan potensi kebocoran data.
3. Target mentah didefinisikan sebagai ln(1 + helpful_vote). Target utama yang dikendalikan terhadap paparan dibentuk dengan mengurangi komponen usia hasil model statistik yang dilatih tanpa menggunakan informasi test dan dengan prediksi out-of-fold pada data training.
4. Fitur model utama saat inferensi terdiri atas embedding BLaIR, rating, verified_purchase, review_length, word_count, dan title_length. Helpful_vote, target turunannya, serta review_age tidak digunakan sebagai fitur input model utama.
5. Model utama menggunakan encoder BLaIR-RoBERTa-Base yang dibekukan dan MLP dengan konfigurasi awal lapisan 256 dan 64 neuron, aktivasi ReLU, dropout 0,2, serta pairwise ranking loss.
6. Pembagian data dilakukan secara product-disjoint dengan proporsi awal 80% training, 10% validation, dan 10% testing pada tingkat parent_asin. Validation digunakan untuk pemilihan model, sedangkan test hanya digunakan untuk evaluasi akhir.
7. Eksperimen skala menggunakan subset training bertingkat sebanyak 100.000, 250.000, 500.000, 750.000, dan 1.000.000 ulasan dengan validation dan test yang sama.
8. Evaluasi utama menggunakan macro-average NDCG@5, NDCG@10, korelasi Spearman, dan MAP per produk. MAE dan RMSE hanya digunakan pada baseline regresi atau keluaran yang dikalibrasi untuk target numerik, bukan langsung pada skor ranking mentah.
9. Penelitian tidak mencakup pengolahan gambar atau video, sistem rekomendasi produk secara menyeluruh, implementasi produksi pada platform e-commerce, maupun klaim kausal mengenai usia dan helpful votes karena riwayat waktu vote tidak tersedia.

2. BAB II
KAJIAN LITERATUR

2.1 Ulasan Produk Daring dan Review Helpfulness

Ulasan produk daring merupakan konten yang dibuat pengguna untuk mendeskripsikan pengalaman, evaluasi, serta pertimbangan setelah menggunakan suatu produk. Dalam perdagangan elektronik, ulasan melengkapi deskripsi resmi dengan informasi penggunaan nyata. Masalah muncul ketika jumlah ulasan terlalu besar dan mutunya beragam; pembaca hanya mampu memeriksa sebagian kecil daftar, sehingga sistem perlu memilih ulasan yang paling informatif. Review helpfulness prediction mempelajari faktor yang membuat ulasan dinilai berguna dan membangun mekanisme otomatis untuk menaksir atau mengurutkan kegunaannya [1], [5].

Helpfulness dapat dipengaruhi isi teks, panjang dan keterbacaan ulasan, rating, status pembelian, karakteristik reviewer, karakteristik produk, serta konteks waktu. Hasil kajian terdahulu tidak selalu konsisten karena dataset, definisi label, dan protokol evaluasinya berbeda [1], [5]. Oleh sebab itu, penelitian ini menggunakan definisi operasional yang tegas: helpful_vote menjadi observasi awal, sedangkan sasaran pemodelan adalah urutan relatif ulasan di dalam produk yang sama.

2.2 Helpful Votes, Kualitas Intrinsik, dan Bias Paparan

Helpful votes menyediakan sinyal perilaku dalam skala besar, tetapi jumlahnya mencampurkan setidaknya dua komponen: mutu informasi ulasan dan kesempatan ulasan untuk dilihat. Ulasan yang lebih lama atau ditampilkan lebih menonjol memiliki peluang lebih besar untuk mengakumulasi vote. Nayeem dan Rafiei menemukan bahwa informasi temporal penting dalam prediksi helpfulness dan bahwa ulasan baru menghadapi masalah cold-start [3]. Dengan demikian, jumlah vote kumulatif tidak boleh diperlakukan sebagai ukuran murni kualitas intrinsik.

Berdasarkan skema publik Amazon Reviews 2023 yang menyertai publikasi dataset [2], data User Reviews mencantumkan helpful_vote, tetapi tidak mencantumkan total vote ataupun riwayat waktu setiap vote. Karena itu, helpfulness ratio tidak dapat dihitung dari atribut yang tersedia dan trajectory historis vote tidak dapat direkonstruksi. Penelitian menggunakan target mentah berikut sebagai proksi awal:

$$y_i = \ln(1 + v_i)$$

dengan v_i menyatakan helpful_vote ulasan ke-i. Transformasi logaritmik mengurangi dominasi nilai ekstrem tanpa mengubah urutan monotonik. Review dengan $v_i = 0$ tetap

dipertahankan karena nol dapat berarti belum memperoleh paparan yang cukup, bukan pasti tidak berguna. Keterbatasan helpful votes sebagai indikator dan kelangkaan vote pada ulasan baru telah menjadi perhatian dalam literatur helpfulness [3], [5].

2.3 Dataset Amazon Reviews 2023

Amazon Reviews 2023 dikembangkan sebagai koleksi berskala besar untuk penelitian yang menghubungkan bahasa, item, pencarian, dan rekomendasi. Publikasi BLaIR melaporkan lebih dari 570 juta ulasan dan sekitar 48 juta item dalam 33 kategori [2]. Penelitian ini menggunakan data User Reviews karena menyediakan teks, rating, waktu publikasi, helpful_vote, serta pengenal produk yang diperlukan untuk membentuk kelompok ranking.

Atribut title dan text digabungkan sebagai masukan encoder; rating, verified_purchase, review_length, word_count, dan title_length menjadi fitur terstruktur; timestamp hanya dipakai untuk menghitung usia dalam analisis serta pembentukan target; helpful_vote membentuk label; parent_asin menjadi unit kelompok dan pemisahan data; sedangkan asin membantu pemeriksaan varian. Nama kolom diverifikasi terhadap skema berkas yang benar-benar diunduh agar perbedaan penamaan tidak menimbulkan kesalahan implementasi [2].

2.4 Representasi Teks: TF-IDF dan Embedding Kontekstual

Algoritma pembelajaran mesin memerlukan representasi numerik dari teks. TF-IDF memberikan bobot tinggi kepada istilah yang sering muncul dalam suatu dokumen tetapi relatif jarang dalam korpus. Representasi ini efisien, bersifat jarang, mudah direproduksi, dan layak digunakan sebagai baseline untuk mengetahui seberapa jauh sinyal leksikal mendukung ranking [6]. Kelemahannya, TF-IDF tidak secara langsung menangkap kesamaan makna antarkalimat yang menggunakan kosakata berbeda.

Embedding kontekstual memetakan teks ke vektor padat dengan mempertimbangkan konteks token. Transformer memperkenalkan mekanisme self-attention yang memungkinkan hubungan antartoken dipelajari tanpa ketergantungan rekuren [7], sedangkan BERT menunjukkan manfaat prapelatihan bidireksional untuk menghasilkan representasi yang dapat dipindahkan ke berbagai tugas bahasa [8]. Dibandingkan TF-IDF, embedding kontekstual lebih mampu menangkap makna, tetapi memerlukan komputasi, memori, dan pengendalian truncation yang lebih besar.

2.5 BLAIR dan Checkpoint BLaIR-RoBERTa-Base

BLAIR merupakan benchmark untuk mengevaluasi encoder semantik dalam skenario rekomendasi, meliputi sequential recommendation, collaborative filtering, dan product search. Benchmark tersebut menekankan bahwa kebutuhan encoder semantik untuk rekomendasi berbeda dari benchmark embedding umum dan sekaligus memperkenalkan Amazon Reviews 2023 [2]. Berbeda dari benchmark tersebut, BLaIR-RoBERTa-Base merujuk pada checkpoint model hyp1231/blair-roberta-base yang digunakan sebagai encoder teks dalam penelitian ini.

Goel et al. mendokumentasikan hyp1231/blair-roberta-base sebagai encoder berbasis RoBERTa yang diprapelatih pada judul ulasan Amazon; mereka memperoleh embedding dari representasi token [CLS] pada lapisan terakhir dan melakukan normalisasi L2 untuk kebutuhan retrieval [14]. Dalam penelitian ini, judul dan isi ulasan ditokenisasi dengan tokenizer checkpoint tersebut, kemudian representasi [CLS] digunakan secara konsisten sebagai embedding. Encoder dibekukan agar embedding dapat dihitung satu kali dan disimpan sehingga eksperimen skala serta ablasi lebih efisien. Strategi ini mengurangi biaya komputasi, tetapi membatasi adaptasi encoder terhadap label helpfulness. Keberhasilan checkpoint pada retrieval atau recommendation tidak serta-merta membuktikan keberhasilan pada review helpfulness ranking; kesesuaiannya tetap harus diuji secara empiris.

2.6 Feature Fusion dan Multi-Layer Perceptron

Feature fusion menggabungkan embedding teks e_i dengan vektor fitur terstruktur z_i menjadi $x_i = [e_i; z_i]$. Fitur numerik dinormalisasi hanya menggunakan statistik training, lalu transformasi yang sama diterapkan pada validation dan test. Penggabungan ini memungkinkan model memanfaatkan informasi semantik sekaligus sinyal eksplisit seperti rating, verified_purchase, dan panjang teks. Helpful_vote, label turunannya, serta review_age dilarang masuk ke fitur model utama agar tidak terjadi kebocoran target atau ketergantungan pada informasi paparan.

MLP merupakan jaringan feed-forward yang dapat mempelajari interaksi nonlinear pada vektor gabungan. Arsitektur awal penelitian terdiri atas lapisan 256 neuron, ReLU, dropout 0,2, lapisan 64 neuron, ReLU, dan satu keluaran skor. Rectified linear units mendukung representasi jarang dan optimasi jaringan dalam [9], sedangkan dropout mengurangi co-adaptation dengan menonaktifkan unit secara acak selama training [10]. Kelebihan MLP adalah kesederhanaan dan fleksibilitas fusi fitur; kekurangannya, struktur

kelompok ranking tidak dipahami tanpa objektif serta prosedur pembentukan pasangan yang tepat.

2.7 Learning to Rank dan Pairwise RankNet

Learning to Rank mempelajari fungsi skor yang menentukan urutan objek. Pendekatan pointwise memperlakukan setiap objek secara individual, pairwise mempelajari preferensi antara dua objek, sedangkan listwise mengoptimalkan satu daftar. Nguyen et al. menunjukkan bahwa objektif listwise dapat lebih selaras dengan ranking keseluruhan, tetapi modelnya lebih kompleks [4]. Penelitian ini memilih pairwise karena pasangan dapat dibentuk di dalam produk yang sama dan skala jutaan ulasan lebih mudah dikelola, dengan konsekuensi bahwa seluruh daftar tidak dioptimalkan secara langsung.

RankNet memperkenalkan biaya probabilistik untuk mempelajari urutan dari pasangan menggunakan jaringan saraf [11]. Untuk dua ulasan i dan j dari produk yang sama dengan target $y_i > y_j$, model diarahkan menghasilkan $s_i > s_j$. Salah satu bentuk loss yang digunakan adalah:

$$\mathbf{L_{ij} = \ln(1 + \exp(-(s_i - s_j)))}$$

Pasangan bertarget sama tidak memberikan arah preferensi dan tidak digunakan. Jumlah pasangan per produk dibatasi agar produk besar tidak mendominasi, sedangkan komposisi pasangan menurut kelompok usia dicatat. Dengan demikian, model mempelajari perbedaan relatif di dalam konteks produk, bukan membandingkan helpful_vote antarproduk yang popularitasnya berbeda.

2.8 Pengukuran dan Pengendalian Pengaruh Usia Ulasan

Usia ulasan dihitung sebagai selisih antara waktu referensi snapshot dan timestamp publikasi. Hubungan usia dengan vote terlebih dahulu dianalisis secara deskriptif melalui distribusi, proporsi nol, kelompok usia, dan korelasi Spearman. Karena helpful_vote merupakan data hitung yang dapat mengalami overdispersi dan kelebihan nol, regresi Poisson hanya layak bila asumsi dispersi terpenuhi; Negative Binomial dipertimbangkan ketika varians melebihi mean [12]. Efek produk diperlukan agar hubungan usia tidak semata-mata mencerminkan popularitas antarproduk.

Bentuk umum model analisis adalah:

$$\mathbf{\ln E[v_i] = \text{alpha_p}(i) + f(\ln(1 + \text{age}_i)) + \text{beta}^T x_i}$$

Fungsi f dapat berupa spline dan ditentukan menggunakan training serta validation. Istilah pengaruh dalam penelitian ini berarti asosiasi setelah mengendalikan produk dan kovariat yang tersedia, bukan efek kausal. Koefisien atau kurva usia, interval kepercayaan,

serta perubahan deviance explained atau pseudo-R2 dilaporkan agar besarnya hubungan tidak hanya dinyatakan secara kualitatif.

2.8.1 Strategi Target dan Pasangan yang Dikendalikan terhadap Usia

Temuan Nayeem dan Rafiei bahwa usia ulasan memengaruhi akumulasi helpful votes memberikan dasar untuk mengendalikan perbedaan kesempatan paparan [3]. Berdasarkan dasar tersebut, penelitian ini merancang dan membandingkan tiga strategi: target mentah, age-matched pairs, dan target terkoreksi usia. Age-matched pairs memprioritaskan pasangan dari produk yang sama dengan usia berdekatan, sehingga perbandingan lebih sedikit dipengaruhi perbedaan durasi paparan. Target terkoreksi usia dirumuskan sebagai:

$$y_i^{adj} = \ln(1 + v_i) - \hat{f}(\ln(1 + age_i))$$

Prediksi f_hat untuk training dibentuk secara out-of-fold agar label tidak menggunakan residual dari model yang melihat observasi yang sama. Model usia untuk validation dan test dipasang hanya pada training. Nilai target terkoreksi dapat negatif dan tetap dapat menentukan arah pasangan. Jika NDCG menggunakan target ini, tingkat relevansi nonnegatif dibentuk berdasarkan batas kuantil yang dipelajari dari training. Ketiga strategi tersebut merupakan rancangan metodologis penelitian ini: usia dipakai sebagai variabel pengendali pada pembentukan target dan pasangan, bukan sebagai masukan model utama saat inferensi.

2.9 Pemisahan Data dan Generalisasi pada Produk Baru

Pemisahan acak pada tingkat baris memungkinkan ulasan dari produk yang sama muncul pada training dan test. Keadaan ini dapat membuat evaluasi terlalu optimistis karena model telah melihat pola produk yang sama. Untuk menilai generalisasi pada produk yang belum terlihat, penelitian ini menetapkan pemisahan kelompok parent_asin menjadi 80% training, 10% validation, dan 10% testing. Keterkaitan asin diperiksa dan duplikasi lintas split dihapus. Product-disjoint split tersebut merupakan protokol evaluasi penelitian ini, bukan prosedur baku yang diambil dari publikasi BLAIR.

Validation digunakan untuk hyperparameter, pemilihan checkpoint, batas kelompok usia, aturan pasangan, dan ambang relevansi MAP. Test digunakan satu kali untuk evaluasi akhir. Untuk eksperimen skala, produk dialokasikan sebelum sampling dan subset training dibuat bertingkat dari 100.000 hingga 1.000.000 ulasan. Validation serta test dipertahankan sama sehingga perubahan performa lebih dapat dikaitkan dengan jumlah data, bukan perubahan komposisi evaluasi.

2.10 Evaluasi Pemeringkatan

NDCG menilai ranking dengan memberi bobot lebih besar pada relevansi di posisi awal dan menormalisasikannya terhadap urutan ideal. Konsep cumulative gain dikembangkan untuk evaluasi dengan tingkat relevansi bertingkat [13]. Penelitian menggunakan NDCG@5 dan NDCG@10 karena antarmuka perdagangan elektronik terutama memerlukan ulasan terbaik pada posisi atas. Definisi gain untuk target mentah dan target terkoreksi ditetapkan sebelum test dan dilaporkan dalam protokol terpisah.

Sebagai pelengkap NDCG, korelasi Spearman digunakan untuk mengukur kesesuaian monotonik antara urutan prediksi dan target per produk, sedangkan MAP mengukur presisi pada posisi ulasan yang memenuhi definisi relevansi biner. Ambang relevansi MAP dipilih hanya menggunakan training atau validation. Semua metrik ranking dihitung per produk lalu dirata-ratakan secara makro agar produk besar tidak mendominasi. Produk dengan target konstan, jumlah ulasan tidak memadai, atau tanpa pasangan relevan ditangani menggunakan aturan yang ditetapkan sebelum evaluasi test, dan jumlah produk valid selalu dilaporkan. Pilihan cut-off, ambang relevansi, macro-average, serta aturan pengecualian tersebut merupakan protokol evaluasi penelitian ini; referensi [13] digunakan khusus sebagai dasar konseptual NDCG.

MAE dan RMSE tidak diterapkan langsung pada skor ranking mentah karena skornya tidak dikalibrasi pada satuan log-vote. Kedua metrik hanya digunakan untuk baseline regresi atau model vote yang memiliki target numerik sepadan. Negative Binomial deviance digunakan untuk menilai model hitung usia. Pemisahan fungsi metrik mencegah kesimpulan yang mencampurkan kualitas urutan dengan akurasi prediksi jumlah vote.

2.11 Penelitian Terdahulu dan Posisi Penelitian

Ocampo Diaz dan Ng merangkum faktor serta metode awal prediksi helpfulness dan menekankan pentingnya mendefinisikan label secara jelas [5]. Du et al. mengidentifikasi 30 fitur berbasis konten dari literatur dan mengevaluasinya pada enam domain Amazon 5-core; representasi semantik menunjukkan kontribusi yang dominan, sedangkan kombinasi beberapa kategori fitur dapat memberikan peningkatan tambahan [1]. Kedua penelitian tersebut memberi dasar pemilihan fitur dan baseline, tetapi tidak secara khusus mengevaluasi BLaIR pada Amazon Reviews 2023 dengan pemisahan produk.

Nayeem dan Rafiei memasukkan expertise reviewer dan dinamika temporal untuk mengatasi cold-start, serta menunjukkan manfaat informasi waktu [3]. Kelebihannya adalah pengakuan eksplisit terhadap sifat temporal vote; keterbatasannya bagi tujuan penelitian ini

adalah ketergantungan model pada usia ketika inferensi. Penelitian ini mengambil arah berbeda: usia digunakan untuk mengukur dan mengoreksi paparan saat pembentukan target, sedangkan model utama hanya menerima fitur yang ditetapkan tersedia pada skenario produksi.

Nguyen et al. mengembangkan konteks listwise untuk multimodal review helpfulness dan menunjukkan keuntungan optimasi daftar [4]. Pendekatan tersebut kuat dalam menangkap konteks antarreviu, tetapi lebih kompleks dan memerlukan modalitas serta rancangan objektif yang berbeda. Penelitian ini membatasi diri pada teks dan fitur terstruktur, menggunakan pairwise RankNet sebagai kompromi antara skalabilitas dan kemampuan mempelajari preferensi, lalu mengakui keterbatasannya melalui baseline dan evaluasi yang konsisten.

Hou et al. memperkenalkan benchmark BLAIR dan Amazon Reviews 2023 untuk mempelajari hubungan bahasa dengan item [2], sedangkan Goel et al. mendokumentasikan penggunaan checkpoint hyp1231/blair-roberta-base sebagai encoder berbasis RoBERTa untuk membentuk representasi semantik [14]. Kedua publikasi tersebut mendukung pemilihan dataset, konteks benchmark, dan checkpoint, tetapi tidak menjawab apakah embedding BLaIR efektif untuk helpfulness ranking. Dengan demikian, posisi penelitian ini berada pada pertemuan empat aspek: representasi BLaIR-RoBERTa-Base, pairwise MLP, generalisasi product-disjoint, serta pengendalian bias usia tanpa review_age pada inferensi. Kontribusi akhirnya harus ditentukan oleh hasil eksperimen, bukan diasumsikan dari kebaruan kombinasi metode.

2.12 Kerangka Pemikiran

Kerangka penelitian dimulai dari Amazon Reviews 2023 yang dibersihkan, dideduplikasi, dan dipisahkan menurut parent_asin. Helpful_vote membentuk target mentah, sedangkan timestamp digunakan untuk mengestimasi hubungan usia-vote dan membentuk alternatif target atau pasangan yang dikendalikan terhadap paparan. Judul serta isi ulasan diproses dengan checkpoint hyp1231/blair-roberta-base; embedding digabungkan dengan fitur terstruktur yang tersedia saat inferensi; MLP kemudian mempelajari skor melalui pasangan ulasan dalam produk yang sama [2], [3], [11], [14].

Keluaran model adalah satu skor per ulasan yang dipakai untuk mengurutkan ulasan dalam setiap produk. Baseline TF-IDF dan linear ranker memisahkan manfaat representasi dari manfaat arsitektur, sedangkan ablasi mengukur kontribusi fitur terstruktur. Lima skala training menguji manfaat pertambahan data, dan product-disjoint test menilai generalisasi.

NDCG, Spearman, dan MAP mengukur mutu ranking; analisis usia serta model count menilai bias paparan. Rangkaian tersebut menghubungkan masalah, data, target, metode, dan evaluasi secara konsisten [1], [4], [13].

BAB III
METODOLOGI PENELITIAN

3.1 Metodologi Penelitian

Penelitian ini menggunakan pendekatan kuantitatif eksperimental untuk membangun dan mengevaluasi sistem pemeringkatan kebermanfaatan ulasan produk. Objek penelitian adalah ulasan pada Amazon Reviews 2023, sedangkan unit pemeringkatan adalah sekumpulan ulasan yang memiliki parent_asin yang sama. Setiap ulasan diberi satu skor oleh model, kemudian skor tersebut digunakan untuk mengurutkan ulasan hanya di dalam produk yang sama. Rancangan penelitian menekankan tiga hal, yaitu generalisasi pada produk yang tidak terlihat selama pelatihan, pengukuran dan pengendalian bias usia ulasan, serta pengujian kontribusi embedding BLaIR dan fitur terstruktur melalui baseline dan ablasi.

Tahapan penelitian meliputi analisis masalah, pengumpulan data sekunder, validasi dan preprocessing, pembagian data product-disjoint, pembentukan target, analisis usia-vote, ekstraksi embedding BLaIR-RoBERTa-Base, feature fusion, pelatihan MLP dengan pairwise ranking loss, dan evaluasi. Review_age digunakan untuk analisis paparan dan pembentukan target, tetapi tidak menjadi fitur model utama ketika inferensi. Dengan batasan tersebut, skor yang dihasilkan diarahkan untuk merepresentasikan kualitas relatif ulasan yang lebih intrinsik, bukan prediksi jumlah vote kumulatif pada horizon tertentu.

3.1.1 Analisis Masalah

Produk populer dapat memiliki ratusan hingga ribuan ulasan, sedangkan pengguna umumnya hanya membaca sebagian kecil ulasan yang ditempatkan pada posisi teratas. Helpful_vote dapat digunakan sebagai sinyal perilaku untuk mengetahui ulasan yang dianggap berguna, tetapi jumlahnya bersifat kumulatif dan dipengaruhi kesempatan paparan. Ulasan lama berpeluang mengumpulkan vote lebih banyak daripada ulasan baru walaupun kualitas informasinya setara. Selain itu, produk yang populer memiliki pola vote berbeda dari produk yang kurang populer. Dengan demikian, penggunaan helpful_vote secara langsung tanpa pengendalian dapat membuat model mempelajari lamanya paparan atau popularitas produk alih-alih kualitas isi ulasan.

Permasalahan kedua adalah kebocoran produk. Apabila ulasan dari produk yang sama tersebar ke training dan testing, model dapat memperoleh petunjuk yang terlalu spesifik terhadap produk dan menghasilkan estimasi performa yang optimistis. Penelitian ini karena itu membagi data berdasarkan parent_asin. Seluruh ulasan suatu produk hanya boleh berada

pada satu split, sedangkan asin diperiksa untuk mengurangi risiko varian yang berhubungan tersebar pada split berbeda.

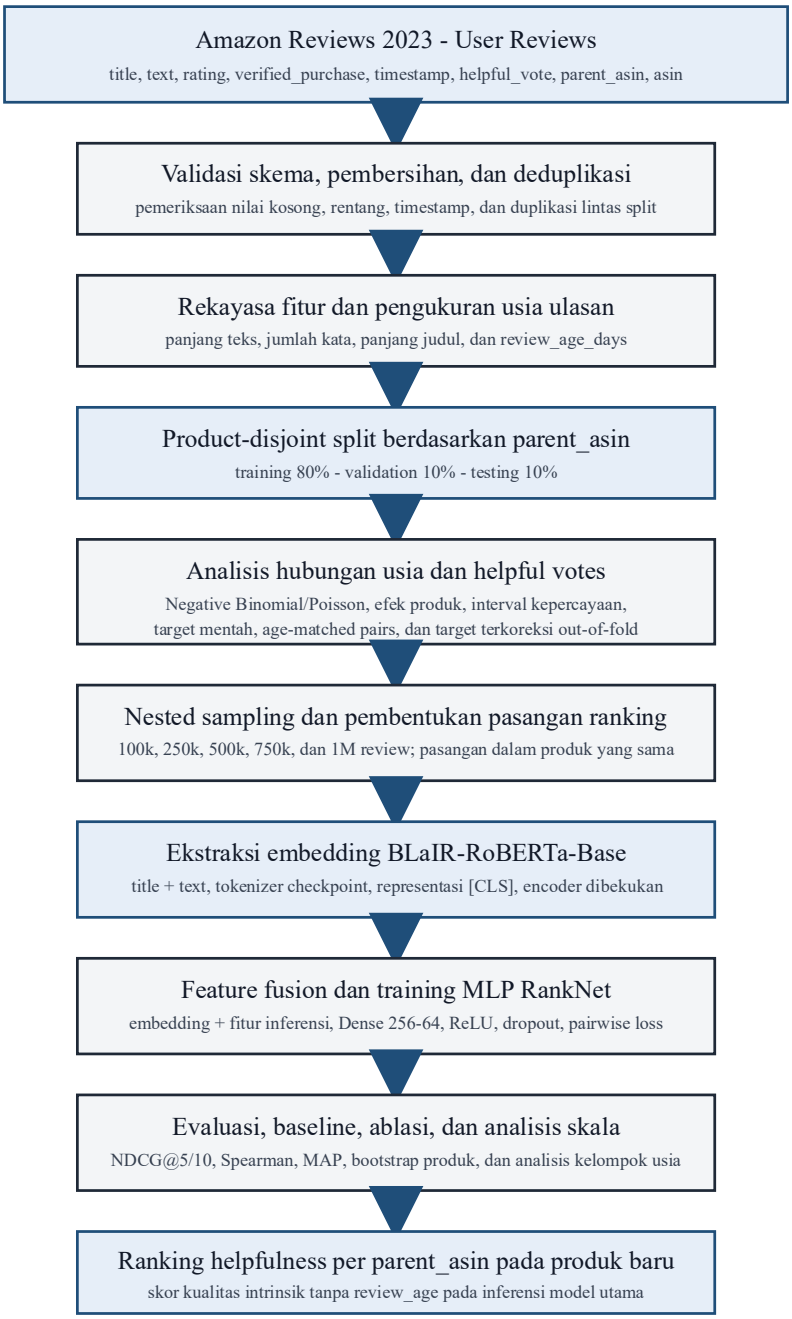
Permasalahan ketiga adalah pemisahan manfaat representasi dan arsitektur. Kinerja model yang baik belum dapat langsung diatribusikan kepada BLaIR apabila tidak dibandingkan dengan TF-IDF, model linear, MLP, serta konfigurasi tanpa fitur terstruktur. Rancangan baseline dan ablasi diperlukan agar kontribusi embedding, model nonlinear, dan fitur tambahan dapat ditafsirkan secara terpisah.

Tabel 3.1 Formulasi input, proses, dan keluaran penelitian

Komponen	Uraian
Input	Judul dan isi ulasan, rating, status verified_purchase, timestamp, helpful_vote, parent_asin, dan asin dari Amazon Reviews 2023.
Proses	Validasi data; preprocessing; product-disjoint split; analisis usia-vote; pembentukan target dan pasangan; embedding BLaIR; feature fusion; training MLP; serta evaluasi ranking.
Keluaran	Skor ranking per ulasan, urutan ulasan per parent_asin, hasil baseline dan ablasi, kurva hubungan usia-vote, serta metrik generalisasi pada produk baru.
Kendala utama	Vote nol yang dominan, distribusi long-tail, perbedaan ukuran produk, bias paparan, keterbatasan komputasi, dan tidak tersedianya riwayat waktu setiap vote.
Kriteria keberhasilan	Peningkatan metrik ranking yang konsisten terhadap baseline pada test product-disjoint, disertai interval kepercayaan dan analisis performa menurut kelompok usia.

3.1.2 Rancangan Penelitian

Rancangan penelitian disusun sebagai alur berurutan dengan titik keputusan yang hanya menggunakan training dan validation. Data test disimpan hingga seluruh aturan preprocessing, target, pasangan, hyperparameter, ambang relevansi, dan model terbaik telah ditetapkan. Diagram alir pada Gambar 3.1 menunjukkan hubungan antara sumber data, pengendalian usia, pembentukan representasi, pelatihan, dan evaluasi.



Gambar 3.1 Diagram alir penelitian

Pelaksanaan penelitian dilakukan melalui langkah-langkah berikut.

1. Mengunduh bagian User Reviews dari Amazon Reviews 2023 dan mencatat kategori, URL, tanggal pengambilan, checksum, ukuran berkas, serta skema kolom.
2. Memvalidasi tipe dan rentang data, menangani nilai kosong, membersihkan teks secara konservatif, menghapus duplikasi, dan memeriksa timestamp serta identitas produk.
3. Menghitung review_length, word_count, title_length, dan review_age_days; selanjutnya mendeskripsikan distribusi helpful_vote, usia, serta ukuran kelompok produk.
4. Membagi kelompok parent_asin menjadi training, validation, dan testing dengan proporsi awal 80:10:10 serta melakukan pemeriksaan kebocoran parent_asin, asin, dan duplikasi teks lintas split.
5. Mengestimasi hubungan usia-vote pada training, menghasilkan prediksi out-of-fold untuk koreksi target training, lalu menerapkan fungsi usia yang dibekukan pada validation dan testing.
6. Membentuk subset training bertingkat, pasangan ranking dalam produk yang sama, dan varian age-matched atau berbobot tanpa memindahkan produk antarsplit.
7. Mengekstraksi embedding title dan text menggunakan checkpoint hyp1231/blair-roberta-base, kemudian menyimpan embedding beserta metadata konfigurasi.
8. Menggabungkan embedding dengan fitur terstruktur yang tersedia saat inferensi dan melatih model baseline serta MLP RankNet.
9. Mengurutkan ulasan berdasarkan skor di setiap parent_asin, menghitung metrik per produk, melakukan macro-average, dan menganalisis performa menurut usia serta ukuran produk.
10. Menyimpan artefak eksperimen, seed, konfigurasi, model, log, pembagian data, dan hasil evaluasi sehingga eksperimen dapat direproduksi.

3.1.3 Sampling / Metode Pemilihan Sampel

Data penelitian merupakan data sekunder, sehingga tidak dilakukan sampling responden lapangan. Populasi operasional adalah seluruh ulasan valid pada kategori Amazon Reviews 2023 yang dipilih. Sampel eksperimen dibentuk setelah pembersihan dan pembagian produk. Pemilihan kategori dilakukan berdasarkan ketersediaan atribut wajib, kecukupan produk dengan lebih dari satu ulasan, dan keterjangkauan komputasi; keputusan kategori serta jumlah baris sebelum dan sesudah filter dicatat secara eksplisit.

Unit sampling adalah parent_asin, bukan baris ulasan. Daftar parent_asin diacak menggunakan seed tetap, kemudian dialokasikan sekitar 80% untuk training, 10% untuk validation, dan 10% untuk testing. Karena ukuran setiap produk berbeda, proporsi jumlah ulasan tidak harus tepat 80:10:10. Produk pada validation dan testing tidak boleh muncul pada training. Jika asin yang sama atau pasangan varian yang teridentifikasi muncul pada lebih dari satu split, seluruh kelompok terkait dipindahkan ke satu split atau dikeluarkan sesuai aturan yang ditetapkan sebelum eksperimen.

Model pairwise memerlukan sekurang-kurangnya dua ulasan dari produk yang sama dengan target berbeda. Produk yang tidak menghasilkan pasangan preferensi tetap dicatat dalam statistik data, tetapi tidak digunakan untuk pembentukan pasangan training. Validation dan testing mempertahankan distribusi alami; SMOTE tidak digunakan karena interpolasi pada embedding dapat menghasilkan ulasan sintetis dan pasangan yang tidak memiliki makna kelompok.

Tabel 3.2 Rancangan split dan sampel training bertingkat

Bagian	Unit alokasi	Proporsi/ukuran	Fungsi
Training	parent_asin	sekitar 80% produk	Pelatihan model, fit preprocessing, model usia, dan pembentukan target out-of-fold.
Validation	parent_asin	sekitar 10% produk	Pemilihan hyperparameter, aturan pasangan, batas usia, threshold MAP, dan early stopping.
Testing	parent_asin	sekitar 10% produk	Evaluasi akhir satu kali pada produk yang tidak terlihat.
E1-E5	review dalam training pool	100k; 250k; 500k; 750k; 1M	Mengukur pengaruh skala dengan subset nested dan validation/testing yang tetap.

Subset E1 sampai E5 dibuat secara nested jika jumlah data memenuhi: E1 merupakan bagian E2, E2 merupakan bagian E3, dan seterusnya. Sampling dibatasi per produk agar produk yang sangat besar tidak mendominasi, sekaligus menjaga representasi tingkat target dan kelompok usia. Identitas baris serta parent_asin setiap subset disimpan agar seluruh model menggunakan sampel yang sama.

3.1.4 Metode Pengumpulan Data

Data dikumpulkan melalui studi dokumentasi terhadap Amazon Reviews 2023 yang dipublikasikan pada https://amazon-reviews-2023.github.io/ dan dijelaskan dalam publikasi

BLAIR [2]. Berkas User Reviews diunduh dari sumber resmi. Setiap berkas dicatat nama, kategori, versi atau tanggal akses, ukuran, jumlah baris, checksum, serta skema aktualnya. Pencatatan tersebut diperlukan karena dataset berskala besar dapat tersedia dalam beberapa kategori dan format.

Atribut wajib diverifikasi sebelum pemrosesan. Timestamp diperiksa satuannya; contoh resmi menggunakan Unix timestamp dalam milidetik, tetapi implementasi tidak mengasumsikan satuan sebelum validasi rentang tanggal. Baris dengan timestamp tidak valid, identitas produk kosong, atau teks yang tidak dapat digunakan ditangani berdasarkan aturan terdokumentasi. Nilai helpful_vote dipastikan berupa bilangan tidak negatif dan rating diperiksa berada pada rentang yang diizinkan dataset.

Tabel 3.3 Atribut data dan perannya dalam penelitian

Atribut	Peran	Digunakan saat inferensi utama
title	Judul ulasan dan bagian input encoder	Ya
text	Isi ulasan dan bagian input encoder	Ya
rating	Fitur terstruktur	Ya
verified_purchase	Fitur terstruktur kategorikal/biner	Ya
timestamp	Perhitungan review_age dan analisis paparan	Tidak
helpful_vote	Pembentukan target dan evaluasi	Tidak
parent_asin	Kelompok ranking dan unit split	Tidak sebagai fitur
asin	Pemeriksaan varian dan kebocoran	Tidak sebagai fitur

Item Metadata tidak menjadi kebutuhan model utama. Metadata hanya dapat ditambahkan pada eksperimen lanjutan, misalnya untuk analisis per kategori. Ketidaktersediaannya tidak mengubah definisi input, target, split, atau evaluasi utama.

3.1.5 Alat-alat Penelitian

Penelitian memerlukan perangkat keras untuk penyimpanan dataset, ekstraksi embedding, dan pelatihan model, serta perangkat lunak untuk pengolahan data, pemodelan statistik, deep learning, dan pencatatan eksperimen. Spesifikasi aktual CPU, RAM, GPU, VRAM, sistem operasi, kapasitas penyimpanan, dan waktu proses dicatat pada saat implementasi. Encoder dibekukan dan embedding disimpan ke disk untuk mengurangi pengulangan komputasi pada eksperimen skala dan ablasi.

Tabel 3.4 Perangkat dan perangkat lunak penelitian

Jenis	Alat	Peruntukan
Perangkat keras	CPU multi-core dan RAM yang memadai	Preprocessing, agregasi per produk, pembentukan pasangan, dan analisis statistik.
Perangkat keras	GPU NVIDIA berkemampuan CUDA dan VRAM yang memadai	Ekstraksi embedding BLaIR dan pelatihan MLP.
Perangkat keras	Penyimpanan SSD	Menyimpan dataset, embedding, split, checkpoint, dan log eksperimen.
Perangkat lunak	Python dan environment terisolasi	Bahasa implementasi serta penguncian dependensi.
Perangkat lunak	PyTorch dan Hugging Face Transformers	Inferensi encoder BLaIR dan pelatihan neural.
Perangkat lunak	Pandas/Polars, NumPy, dan scikit-learn	Pemrosesan data, transformasi fitur, baseline, dan metrik.
Perangkat lunak	statsmodels/SciPy	Model count, korelasi, interval kepercayaan, dan uji statistik.
Perangkat lunak	Matplotlib/Seaborn	Visualisasi distribusi, kurva usia-vote, dan hasil eksperimen.
Perangkat lunak	Git dan pencatat eksperimen	Kontrol versi kode, konfigurasi, seed, dan artefak hasil.

Versi library, checkpoint, tokenizer, commit kode, dan konfigurasi environment dibekukan pada setiap run. Jika keterbatasan memori mengharuskan pemrosesan bertahap, data dibaca secara streaming atau per shard, embedding disimpan dalam tipe numerik yang terdokumentasi, dan kesetaraan hasil terhadap sampel kecil diverifikasi.

3.1.6 Teknik Analisis dan Rencana Strategi

Teknik analisis menggabungkan statistik deskriptif, pemodelan count untuk hubungan usia-vote, learning to rank, dan evaluasi berbasis kelompok produk. Seluruh keputusan yang dapat memengaruhi performa ditentukan menggunakan training dan validation. Tahapan teknisnya dijelaskan sebagai berikut.

Preprocessing dan pengendalian kualitas data.

Teks dibersihkan secara konservatif dengan normalisasi spasi dan karakter kendali tanpa menghapus negasi, angka, tanda baca bermakna, atau informasi semantik. Nilai title kosong dapat diganti string kosong apabila text tersedia, sedangkan baris tanpa isi review yang dapat digunakan dikeluarkan. Duplikasi diperiksa melalui identitas review apabila tersedia dan

melalui kombinasi parent_asin, asin, timestamp, title, text, serta rating. Pemeriksaan hash teks dilakukan lintas split setelah alokasi produk untuk mendeteksi salinan yang dapat menyebabkan kebocoran.

Fitur terstruktur dihitung sebelum training, tetapi parameter transformasinya hanya dipelajari dari training. Review_length adalah jumlah karakter isi review, word_count adalah jumlah token berbasis pemisahan spasi setelah normalisasi, dan title_length adalah jumlah karakter judul. Fitur panjang ditransformasi dengan ln(1+x) bila distribusinya sangat menceng, lalu distandardisasi menggunakan rata-rata dan simpangan baku training. Verified_purchase dipetakan secara konsisten ke nilai biner; kategori tidak dikenal pada validation/testing ditangani dengan aturan eksplisit.

Pembentukan target mentah.

Dataset menyediakan helpful_vote tetapi tidak menyediakan total_votes, sehingga helpfulness ratio tidak dapat dihitung secara valid. Target observasi awal ditetapkan sebagai transformasi logaritmik berikut.

$$y_i = \ln(1 + v_i)$$

Pada persamaan tersebut, v_i adalah helpful_vote ulasan ke-i. Transformasi logaritmik mengurangi pengaruh nilai ekstrem tanpa mengubah urutan monotonik. Helpful_vote dan seluruh turunannya tidak pernah dimasukkan sebagai fitur. Ulasan dengan vote nol dipertahankan karena nol dapat menunjukkan belum adanya paparan yang cukup.

Pengukuran dan koreksi pengaruh usia.

Usia ulasan dihitung dalam hari dari satu waktu referensi snapshot yang konsisten. T_ref diambil dari tanggal snapshot resmi; apabila tanggal tersebut tidak tersedia, maksimum timestamp valid pada snapshot digunakan dan keputusan ini dicatat. Timestamp yang melebihi T_ref dianggap tidak valid.

$$\text{review_age_days}_i = (T_{ref} - \text{timestamp}_i) / 86.400.000$$

Hubungan usia dan vote terlebih dahulu dideskripsikan melalui distribusi vote, proporsi nol, median, mean, kuantil, serta korelasi Spearman antara ln(1+age) dan helpful_vote. Ringkasan disajikan secara keseluruhan dan per kelompok usia yang batasnya dipelajari dari training. Istilah pengaruh dalam penelitian ini merujuk pada asosiasi setelah pengendalian produk dan kovariat yang tersedia, bukan efek kausal.

Model count awal adalah Negative Binomial karena helpful_vote diperkirakan overdispersed. Poisson digunakan hanya jika pemeriksaan dispersi mendukung. Bentuk model adalah sebagai berikut.

$$\ln E[v_i] = \text{alpha_p(i)} + f(\ln(1 + \text{age_i})) + \text{beta}^T x_i$$

Alpha_p(i) adalah efek produk, f(.) adalah fungsi usia linear atau spline, dan x_i memuat kovariat nonteks seperti rating, verified_purchase, serta panjang ulasan. Kompleksitas spline, regularisasi, dan bentuk model dipilih menggunakan training/validation. Hasil dilaporkan sebagai kurva usia beserta interval kepercayaan 95%, perubahan vote yang diharapkan, serta tambahan deviance explained atau pseudo-R2 dibandingkan model tanpa usia [12].

Target terkoreksi usia hanya mengurangi komponen paparan usia yang telah dipusatkan pada distribusi training; efek produk dan kovariat lain tidak dikurangkan. Prediksi komponen usia untuk baris training dibuat melalui K-fold out-of-fold berdasarkan kelompok produk. Model usia untuk validation dan testing hanya dilatih pada training. Rumus targetnya adalah:

$$y_i(\text{adj}) = \ln(1 + v_i) - \text{f_hat}(\ln(1 + \text{age_i}))$$

Target terkoreksi dapat bernilai negatif dan tetap digunakan untuk menentukan arah preferensi pasangan. Untuk NDCG, nilai tersebut dipetakan ke tingkat relevansi nonnegatif 0-4 menggunakan batas kuantil yang hanya dihitung dari training. Hasil berbasis target mentah dan target terkoreksi dilaporkan dalam tabel terpisah dan tidak dibandingkan sebagai angka yang identik.

Product-disjoint split dan pencegahan kebocoran.

Urutan operasi dijaga agar tidak terjadi kebocoran: deduplikasi global dan validasi identitas dilakukan sebelum split; alokasi dilakukan pada parent_asin; fit scaler, encoder kategorikal, kuantil, model usia, dan aturan pasangan dilakukan pada training; pemilihan hyperparameter dilakukan pada validation; dan testing digunakan satu kali. Daftar produk, identitas baris, serta checksum setiap split disimpan. Pemeriksaan assert memastikan irisan parent_asin antarsplit kosong dan salinan teks lintas split telah ditangani.

Ekstraksi embedding BLaIR.

Masukan encoder dibentuk dari title dan text dengan pemisah tokenizer checkpoint hyp1231/blair-roberta-base. Tokenisasi, special token, panjang maksimum, padding, dan truncation mengikuti konfigurasi checkpoint dan dicatat. Jika teks melebihi panjang maksimum, strategi truncation mempertahankan judul dan bagian awal isi secara

deterministik. Representasi token [CLS] pada lapisan terakhir digunakan sebagai embedding dan normalisasi L2 diuji sesuai dokumentasi checkpoint [14]. Encoder dibekukan pada eksperimen utama; embedding dihitung tanpa gradien, disimpan, lalu diverifikasi keterkaitannya dengan identitas baris.

Feature fusion dan arsitektur MLP.

Embedding e_i digabungkan dengan vektor fitur terstruktur z_i menjadi x_i = [e_i; z_i]. Fitur model utama hanya mencakup informasi yang tersedia saat inferensi: embedding teks, rating, verified_purchase, review_length, word_count, dan title_length. Review_age, helpful_vote, target, parent_asin, serta asin tidak menjadi input prediktif.

Tabel 3.5 Konfigurasi awal model MLP ranking

Komponen	Konfigurasi awal
Input	Embedding BLaIR + fitur terstruktur tertransformasi
Hidden layer 1	Dense 256 neuron + ReLU
Regularisasi	Dropout 0,2
Hidden layer 2	Dense 64 neuron + ReLU
Output	Satu skor ranking tanpa aktivasi
Optimizer	Adam; learning rate dan weight decay ditentukan pada validation
Loss	Pairwise logistic loss bergaya RankNet
Kontrol training	Mini-batch pasangan, early stopping NDCG@10 validation, gradient clipping bila diperlukan

Pasangan (i,j) hanya dibentuk dari ulasan dalam parent_asin yang sama dan digunakan jika target i lebih tinggi daripada target j. Untuk skor s_i dan s_j, loss pasangan didefinisikan sebagai berikut [11].

$$L_{ij} = \ln(1 + \exp(-(s_i - s_j)))$$

Pasangan dengan target sama tidak menghasilkan preferensi. Jumlah pasangan per produk dibatasi, arah pasangan diacak secara seimbang, dan produk besar tidak boleh mendominasi mini-batch. Pada varian age-matched, pasangan diprioritaskan jika selisih usia berada di bawah batas yang dipilih pada validation. Pada varian pembobotan, pasangan lintas usia diberi bobot yang ditentukan pada validation dan proporsinya selalu dilaporkan.

Rancangan eksperimen.

Tabel 3.6 Matriks eksperimen penelitian

Kelompok	Varian	Tujuan
Skala	100k; 250k; 500k; 750k; 1M review	Mengukur perubahan performa akibat penambahan data training.
Baseline	TF-IDF + linear; TF-IDF + MLP; BLaIR + linear	Memisahkan manfaat representasi dan arsitektur.
Model utama	BLaIR + MLP; BLaIR + fitur + MLP	Mengukur manfaat nonlinearitas dan feature fusion.
Ablasi	Embedding saja; +rating; +verified; +seluruh fitur inferensi	Mengukur kontribusi fitur terstruktur.
Kontrol usia	Target mentah; age-matched; target OOF terkoreksi; koreksi + bobot lintas usia	Mengukur dampak strategi pengendalian paparan.
Oracle	Model tambahan dengan review_age	Mengukur upper bound informasi usia; bukan model produksi.

Seluruh varian dalam satu perbandingan menggunakan split, sampel, target, dan protokol evaluasi yang setara. Minimal tiga seed digunakan untuk training model neural; nilai rata-rata dan simpangan baku antarseed dilaporkan. Model terbaik dipilih berdasarkan NDCG@10 macro pada validation. Fine-tuning penuh encoder tidak menjadi eksperimen utama dan hanya dapat ditambahkan sebagai analisis lanjutan jika sumber daya memungkinkan.

Evaluasi model dan analisis statistik.

Tabel 3.7 Metrik dan aturan evaluasi

Metrik	Penggunaan	Aturan utama
NDCG@5	Kualitas lima posisi teratas	Dihitung per produk dengan IDCG > 0, lalu macro-average.
NDCG@10	Metrik utama kualitas ranking	Cut-off menggunakan min(k,n); target mentah dan terkoreksi dilaporkan terpisah [13].
Spearman	Kesesuaian urutan monotonik	Produk minimal tiga ulasan dan target tidak konstan.
MAP	Presisi posisi relevan	Produk memiliki minimal satu relevan dan satu nonrelevan; threshold dibekukan dari training/validation.
MAE/RMSE	Akurasi prediksi ln(1+vote)	Hanya untuk baseline regresi atau keluaran terkalibrasi, bukan skor ranking mentah.
NB deviance	Kecocokan model count usia	Dibandingkan dengan model tanpa komponen usia.

NDCG, Spearman, dan MAP dihitung untuk setiap produk, kemudian dirata-ratakan secara makro agar produk besar tidak mendominasi. Untuk target mentah, gain berasal dari ln(1+helpful_vote); untuk target terkoreksi, gain berasal dari tingkat relevansi 0-4 yang ditetapkan oleh kuantil training. Threshold biner MAP dipilih dari kandidat yang ditentukan sebelum testing, misalnya vote positif atau kuantil relevansi, dengan validation sebagai dasar pemilihan.

Produk dengan kurang dari dua ulasan valid dikeluarkan dari metrik ranking. Produk dengan target konstan dikeluarkan dari Spearman dan analisis preferensi; produk tanpa relevan atau tanpa nonrelevan dikeluarkan dari MAP. Jumlah produk valid, jumlah ulasan, dan alasan eksklusi dilaporkan untuk setiap metrik. Performa juga disajikan menurut kelompok review baru, menengah, dan lama serta menurut ukuran kelompok produk.

Ketidakpastian hasil diestimasi dengan bootstrap pada tingkat parent_asin sebanyak 1.000 replikasi sehingga struktur ulasan dalam produk tetap utuh. Perbandingan dua model menggunakan selisih metrik per produk dan interval kepercayaan 95%; klaim peningkatan hanya dibuat jika arah perbedaan konsisten, besar efek dilaporkan, dan tidak hanya bergantung pada satu seed. Analisis usia menyajikan interval kepercayaan kurva dan uji sensitivitas terhadap batas kelompok usia, bentuk spline, serta aturan pasangan.

Reproduksibilitas dan kriteria penghentian.

- Menetapkan seed untuk split produk, sampling E1-E5, fold model usia, pembentukan pasangan, dan inisialisasi model.
- Menyimpan konfigurasi checkpoint, tokenizer, pooling, panjang token, scaler, threshold, kuantil, hyperparameter, waktu proses, penggunaan RAM/VRAM, dan kapasitas penyimpanan.
- Menyimpan model usia, prediksi out-of-fold, embedding, daftar produk tiap split, identitas sampel nested, checkpoint terbaik, dan hasil per produk.
- Menggunakan early stopping berdasarkan NDCG@10 validation dengan patience yang ditetapkan sebelum test; training dihentikan jika tidak ada perbaikan atau batas epoch tercapai.
- Menjalankan pemeriksaan otomatis bahwa fitur terlarang tidak masuk ke tensor model dan bahwa irisan parent_asin antarsplit kosong.

Luaran akhir penelitian adalah model yang menghasilkan skor ranking untuk setiap ulasan dan dapat diterapkan pada produk baru tanpa memerlukan review_age pada inferensi. Hasil terhadap target mentah tetap dilaporkan sebagai pembanding, sedangkan hasil target terkoreksi usia menjadi dasar penilaian kualitas yang lebih sedikit dipengaruhi kesempatan paparan. Apabila tujuan bergeser menjadi prediksi jumlah vote kumulatif pada horizon tertentu, review_age atau horizon harus ditambahkan pada tahap kalibrasi dan dievaluasi sebagai tugas yang berbeda.

3. BAB IV
HASIL DAN PEMBAHASAN

4. 4.1 Hasil

Subbab Hasil harus menyesuaikan dengan judul / topik Skripsi / Tesis yang diangkat. Subbab Hasil dapat berupa temuan-temuan sebagai bentuk implementasi penyelesaian masalah atau hasil pengujian yang dilakukan sesuai dengan ruang lingkup yang telah ditentukan. Subbab Hasil dapat dipecah menjadi beberapa sub-sub bab sesuai dengan kebutuhan, sementara hasil tersebut harus dievaluasi / dikaji / didiskusikan untuk mengisi subbab Pembahasan.

5. 4.2 Pembahasan

Subbab Pembahasan harus menyesuaikan dengan hasil pengujian dan dapat diuraikan dalam beberapa sub-sub bab sesuai kebutuhan. Pembahasan menjawab masalah yang diajukan pada Bab I.

6. BAB V
PENUTUP

Pada Program Sarjana (S-1), subbab Penutup dapat berisi Rangkuman atau dibagi dalam Kesimpulan dan Saran, sedangkan pada Program Magister (S-2), subbab Penutup dapat berisi Kesimpulan dan Saran.

Kesimpulan merupakan rangkuman yang diperoleh sebagai hasil akhir dari pelaksanaan penelitian. Kesimpulan harus rinci dan teliti sebagai inti sari dari hasil analisis, rancangan dan pengujian data / sistem / prototype model, dan / atau rencana strategi, temuan-temuan, interpretasi yang menjawab rumusan masalah. Sekurang-kurangnya setiap masalah penelitian menghasilkan satu temuan / jawaban. Kesimpulan adalah pernyataan mengenai generalisasi dari hasil penelitian. Dalam membuat kesimpulan, perlu diperhatikan bahwa hanya ada 1 (satu) kesimpulan untuk suatu hipotesis (jika penelitian yang dilakukan memperkenalkan hipotesis).

Saran ditujukan kepada teori / ilmu pengetahuan / dunia akademik, praktek / aplikasi terapan ke instansi / organisasi / objek penelitian untuk perumusan kebijakan lanjut, dan untuk penelitian lebih lengkap selanjutnya. Saran tidak boleh keluar dari topik penelitian dan harus rinci dan merupakan tindak lanjut yang dapat dilakukan untuk penelitian yang lebih jauh atau lebih dalam.

7. DAFTAR PUSTAKA

[1] J. Du, J. Rong, S. Michalska, H. Wang, and Y. Zhang, "Feature selection for helpfulness prediction of online product reviews: An empirical study," PLOS ONE, vol. 14, no. 12, art. no. e0226902, 2019, doi: 10.1371/journal.pone.0226902. [Buka paper]

[2] Y. Hou, J. Li, X. Fu, Z. He, A. Yan, X. Chen, and J. McAuley, "Bridging Language and Items for Retrieval and Recommendation: Benchmarking LLMs as Semantic Encoders," in Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2026, pp. 3251-3265, doi: 10.18653/v1/2026.acl-long.147. [Buka paper]

[3] M. T. Nayeem and D. Rafiei, "On the Role of Reviewer Expertise in Temporal Review Helpfulness Prediction," in Findings of the Association for Computational Linguistics: EACL 2023, 2023, pp. 1684-1692, doi: 10.18653/v1/2023.findings-eacl.125. [Buka paper]

[4] T. Nguyen, X. Wu, X. Dong, A. T. Luu, C.-D. Nguyen, Z. Hai, and L. Bing, "Gradient-Boosted Decision Tree for Listwise Context Model in Multimodal Review Helpfulness Prediction," in Findings of the Association for Computational Linguistics: ACL 2023, 2023, pp. 1670-1696, doi: 10.18653/v1/2023.findings-acl.106. [Buka paper]

[5] G. Ocampo Diaz and V. Ng, "Modeling and Prediction of Online Product Review Helpfulness: A Survey," in Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2018, pp. 698-708, doi: 10.18653/v1/P18-1065. [Buka paper]

[6] A. Gasparetto, M. Marcuzzo, A. Zangari, and A. Albarelli, "A Survey on Text Classification Algorithms: From Text to Predictions," Information, vol. 13, no. 2, art. no. 83, 2022, doi: 10.3390/info13020083. [Buka paper]

[7] A. Vaswani et al., "Attention Is All You Need," in Advances in Neural Information Processing Systems 30, 2017, pp. 5998-6008. [Buka paper]

[8] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in Proceedings of NAACL-HLT 2019, 2019, pp. 4171-4186, doi: 10.18653/v1/N19-1423. [Buka paper]

[9] X. Glorot, A. Bordes, and Y. Bengio, "Deep Sparse Rectifier Neural Networks," in Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, vol. 15, 2011, pp. 315-323. [Buka paper]

[10] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A Simple Way to Prevent Neural Networks from Overfitting," Journal of Machine Learning Research, vol. 15, no. 56, pp. 1929-1958, 2014. [Buka paper]

[11] C. J. C. Burges, T. Shaked, E. Renshaw, A. Lazier, M. Deeds, N. Hamilton, and G. N. Hullender, "Learning to Rank Using Gradient Descent," in Proceedings of the 22nd International Conference on Machine Learning, 2005, pp. 89-96, doi: 10.1145/1102351.1102363. [Buka paper]

[12] B. Pittman, E. Buta, S. Krishnan-Sarin, and S. S. O'Malley, "Models for Analyzing Zero-Inflated and Overdispersed Count Data: An Application to Cigarette and Marijuana Use," Nicotine &

Tobacco Research, vol. 22, no. 8, pp. 1390-1398, 2020, doi: 10.1093/ntr/nty072. [Buka paper]

[13] K. Jarvelin and J. Kekalainen, "Cumulated Gain-Based Evaluation of IR Techniques," ACM Transactions on Information Systems, vol. 20, no. 4, pp. 422-446, 2002, doi: 10.1145/582415.582418. [Buka paper]

[14] A. Goel, P. A. Chitale, B. Paliwal, B. Santra, and A. Sharma, "HORIZON: A Benchmark for In-the-wild User Behaviour Modeling," in Findings of the Association for Computational Linguistics: ACL 2026, 2026, pp. 30060-30078, doi: 10.18653/v1/2026.findings-acl.1503. [Buka paper]